

机器学习

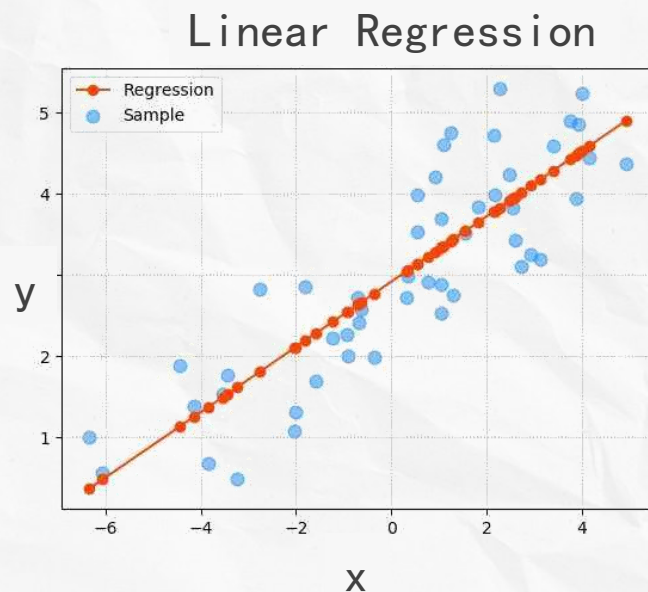
线性回归

涂文婷

tu.wenting@mail.shufe.edu.cn

线性回归

◦ 定义



$$f_{\text{瓜甜}}(x) = 0.2 \cdot x_{\text{色泽}} + 0.5 \cdot x_{\text{根蒂}} + 0.3 \cdot x_{\text{敲声}} + 1$$


线性回归

◦ 最小二乘法

设定模型的形式: $f(\mathbf{x}) = w_1x_1 + w_2x_2 + \dots + w_dx_d + b$

设定误差的形式: $\ell(f(\mathbf{x}_i), y_i) = (f(\mathbf{x}_i) - y_i)^2$

利用最小化训练误差求解模型参数: $\arg \min_{(w,b)} \sum_{i=1}^m (f(x_i) - y_i)^2 = \arg \min_{(w,b)} \sum_{i=1}^m (y_i - wx_i - b)^2$



线性回归

◦ 最小二乘法

设定模型的形式: $f(\mathbf{x}) = w_1x_1 + w_2x_2 + \cdots + w_dx_d + b$

设定误差的形式: $\ell(f(\mathbf{x}_i), y_i) = (f(\mathbf{x}_i) - y_i)^2$

利用最小化训练误差求解模型参数:

$$\arg \min_{(w,b)} \sum_{i=1}^m (f(\mathbf{x}_i) - y_i)^2 = \arg \min_{(w,b)} \sum_{i=1}^m (y_i - wx_i - b)^2$$

解析解:

$$w = \frac{\sum_{i=1}^m y_i (x_i - \bar{x})}{\sum_{i=1}^m x_i^2 - \frac{1}{m} (\sum_{i=1}^m x_i)^2}, \bar{x} = \frac{1}{m} \sum_{i=1}^m x_i$$

$$b = \frac{1}{m} \sum_{i=1}^m (y_i - wx_i)$$

线性回归

◦ 最小二乘法

$$\mathbf{X} = \begin{pmatrix} x_{11} & x_{12} & \dots & x_{1d} & 1 \\ x_{21} & x_{22} & \dots & x_{2d} & 1 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ x_{m1} & x_{m2} & \dots & x_{md} & 1 \end{pmatrix} = \begin{pmatrix} \mathbf{x}_1^T & 1 \\ \mathbf{x}_2^T & 1 \\ \vdots & \vdots \\ \mathbf{x}_m^T & 1 \end{pmatrix}$$

$$\mathbf{y} = (y_1; y_2; \dots; y_m)$$

$$\hat{\mathbf{w}}^* = \arg \min_{\hat{\mathbf{w}}} (\mathbf{y} - \mathbf{X}\hat{\mathbf{w}})^T (\mathbf{y} - \mathbf{X}\hat{\mathbf{w}})$$

$$E_{\hat{\mathbf{w}}} = (\mathbf{y} - \mathbf{X}\hat{\mathbf{w}})^T (\mathbf{y} - \mathbf{X}\hat{\mathbf{w}})$$

$$\frac{\partial E_{\hat{\mathbf{w}}}}{\partial \hat{\mathbf{w}}} = 2\mathbf{X}^T(\mathbf{X}\hat{\mathbf{w}} - \mathbf{y})$$

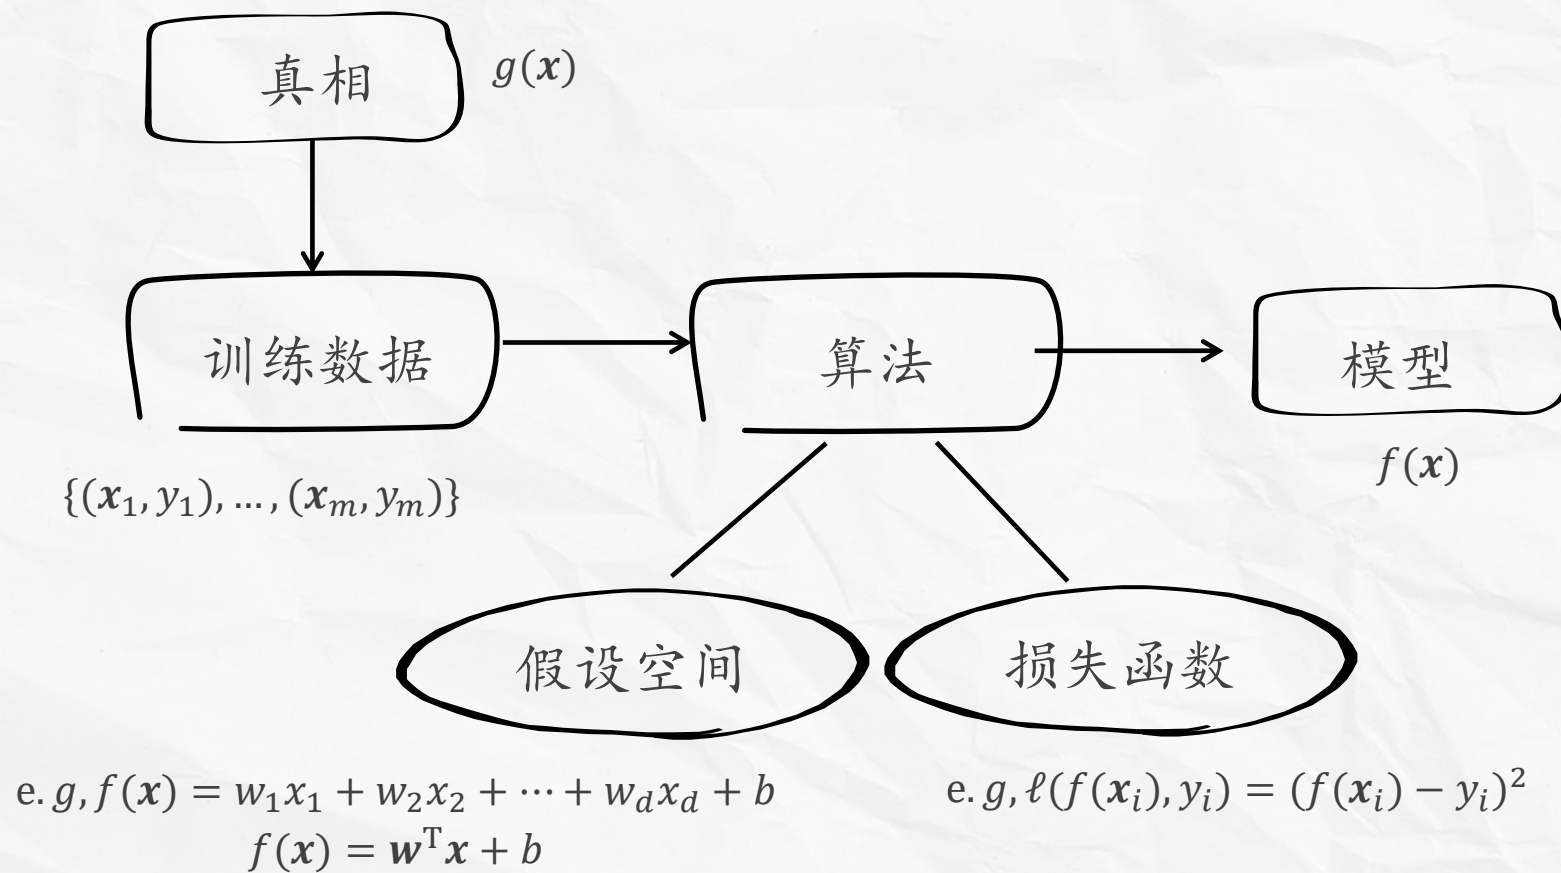
$$\hat{\mathbf{w}}^* = (\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T\mathbf{y}$$

$$f(\hat{\mathbf{x}}_i) = \hat{\mathbf{x}}_i^T (\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T\mathbf{y}, \quad \hat{\mathbf{x}}_i = (\mathbf{x}_i, 1)$$

现实任务中 $\mathbf{X}^T\mathbf{X}$ 往往不是满秩矩阵，此时此时可解出多个 $\hat{\mathbf{w}}$ ，都能使均方误差最小化。选择哪一个解作为输出将由学习算法的归纳偏好决定，常见的做法是引入正则化（regularization）项。

线性回归

机器学习框架



线性回归

◦ 正则化技术

> 一般形式

$$\min_f \Omega(f) + \sum_{i=1}^m \ell(f(\mathbf{x}_i), y_i)$$

结构风险用于描述模型的某些性质

经验风险用于描述模型与训练数据的契合程度

线性回归

◦ 正则化技术


> Ridge 岭回归

$$\min_{w,b} \| \mathbf{y} - \mathbf{X}\hat{\mathbf{w}} \|_2^2 + \lambda \| \mathbf{w} \|_2^2, \quad \| \mathbf{w} \|_2^2 = \sum_{j=1}^d w_j^2$$

$$\min_{w,b} (\mathbf{y} - \mathbf{X}\hat{\mathbf{w}})^T (\mathbf{y} - \mathbf{X}\hat{\mathbf{w}}) + \lambda \| \mathbf{w} \|_2^2$$

$$f(x) = w_0 + w_1x + w_2x^2 + w_3x^3 + \cdots + w_Mx^M$$

$$\min_{w,b} \| \mathbf{y} - \mathbf{X}\mathbf{w} \|_2^2 + \lambda \| \mathbf{w} \|_2^2$$



线性回归

◦ 正则化技术

> LASSO

$$\min_{\mathbf{w}, b} \|\mathbf{y} - \mathbf{X}\hat{\mathbf{w}}\|_2^2 + \lambda \|\mathbf{w}\|_1, \quad \|\mathbf{w}\|_1 = \sum_{j=1}^d |w_j|$$

$$\min_{\mathbf{w}, b} (\mathbf{y} - \mathbf{X}\hat{\mathbf{w}})^T (\mathbf{y} - \mathbf{X}\hat{\mathbf{w}}) + \lambda \|\mathbf{w}\|_1$$

> ElasticNet

$$\min_{\mathbf{w}, b} \|\mathbf{y} - \mathbf{X}\hat{\mathbf{w}}\|_2^2 + \lambda_1 \|\mathbf{w}\|_1 + \lambda_2 \|\mathbf{w}\|_2^2$$

线性回归

- Lasso in Sklearn

https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.Lasso.html

- ElasticNet in Sklearn

https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.ElasticNet.html

扩展：梯度下降法求解的线性回归

◦ 梯度下降法

考虑无约束优化问题 $\min_{\boldsymbol{\theta}} \mathcal{L}(\boldsymbol{\theta})$

若能构造一个序列 $\boldsymbol{\theta}^0, \boldsymbol{\theta}^1, \boldsymbol{\theta}^2, \dots$

满足 $\mathcal{L}(\boldsymbol{\theta}^{t+1}) < \mathcal{L}(\boldsymbol{\theta}^t)$, $t=0, 1, 2, \dots$

则不断执行该过程即可收敛到局部极小点

根据泰勒展式有 $\mathcal{L}(\boldsymbol{\theta} + \Delta\boldsymbol{\theta}) \simeq \mathcal{L}(\boldsymbol{\theta}) + \Delta\boldsymbol{\theta}^T \nabla \mathcal{L}(\boldsymbol{\theta})$

于是, 欲满足 $\mathcal{L}(\boldsymbol{\theta} + \Delta\boldsymbol{\theta}) < \mathcal{L}(\boldsymbol{\theta})$

可选择 $\Delta\boldsymbol{\theta} = -\eta \nabla \mathcal{L}(\boldsymbol{\theta})$

其中步长 η 是一个小常数. 这就是梯度下降法

扩展：梯度下降法求解的线性回归

◦ 梯度下降法求解最小二乘法

> 批量梯度下降

$$w^{(t+1)} = w^{(t)} - \eta \nabla \mathcal{L}$$

$$w^{(t+1)} = w^{(t)} + \eta \sum_{i=1}^m (y_i - w^{(t)T} x_i) x_i$$

> 随机梯度下降

$$w^{(t+1)} = w^{(t)} - \eta \nabla \mathcal{L}_i$$

$$w^{(t+1)} = w^{(t)} + \eta (y_i - w^{(t)T} x_i) x_i$$

扩展：利用线性回归实现多项式回归

◦ 多项式回归

原始特征集

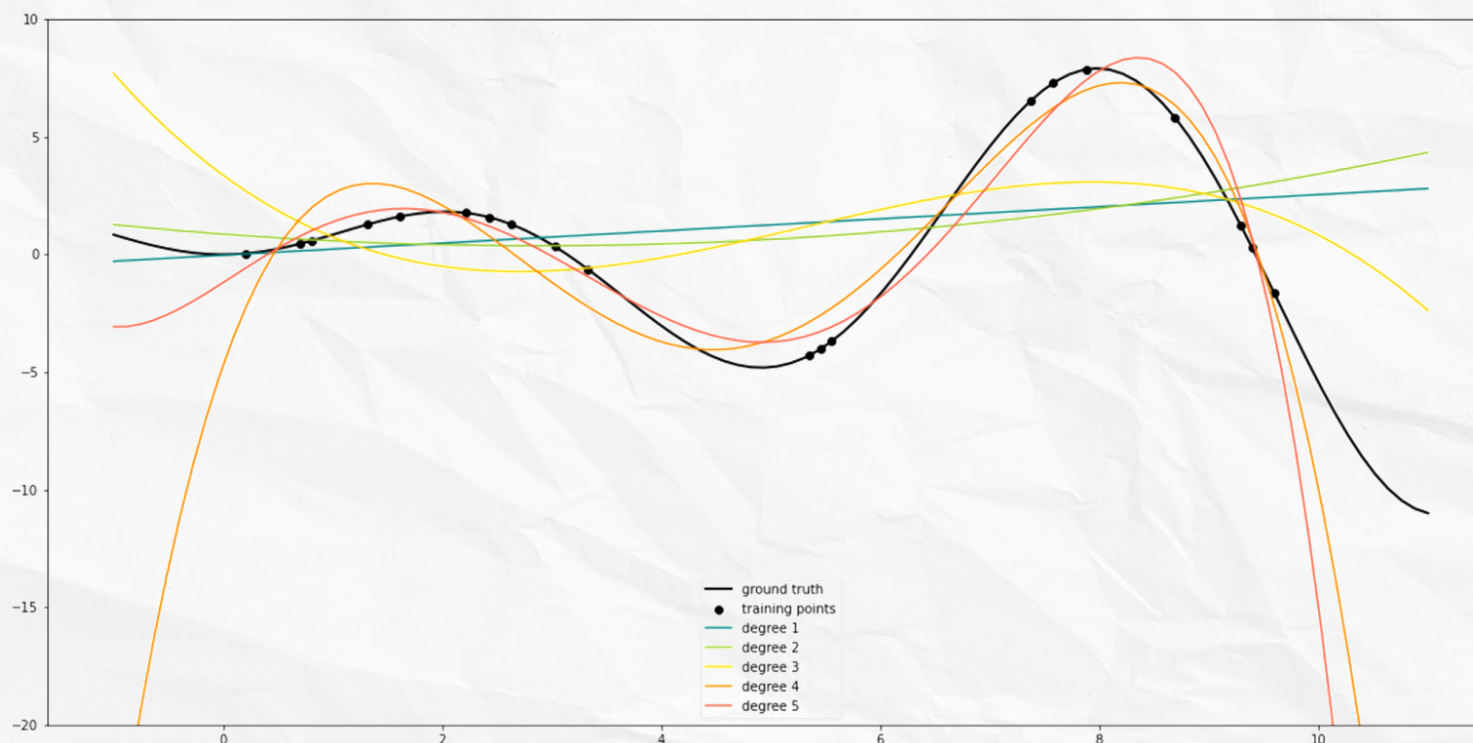
$$(x_1, x_2)$$

$$(x_1, x_2, x_3)$$

变换后特征集

$$(1, x_1, x_2, x_1^2, x_1x_2, x_2^2)$$

$$(1, x_1, x_2, x_3, x_1x_2, x_1x_3, x_2x_3, x_1x_2x_3)$$



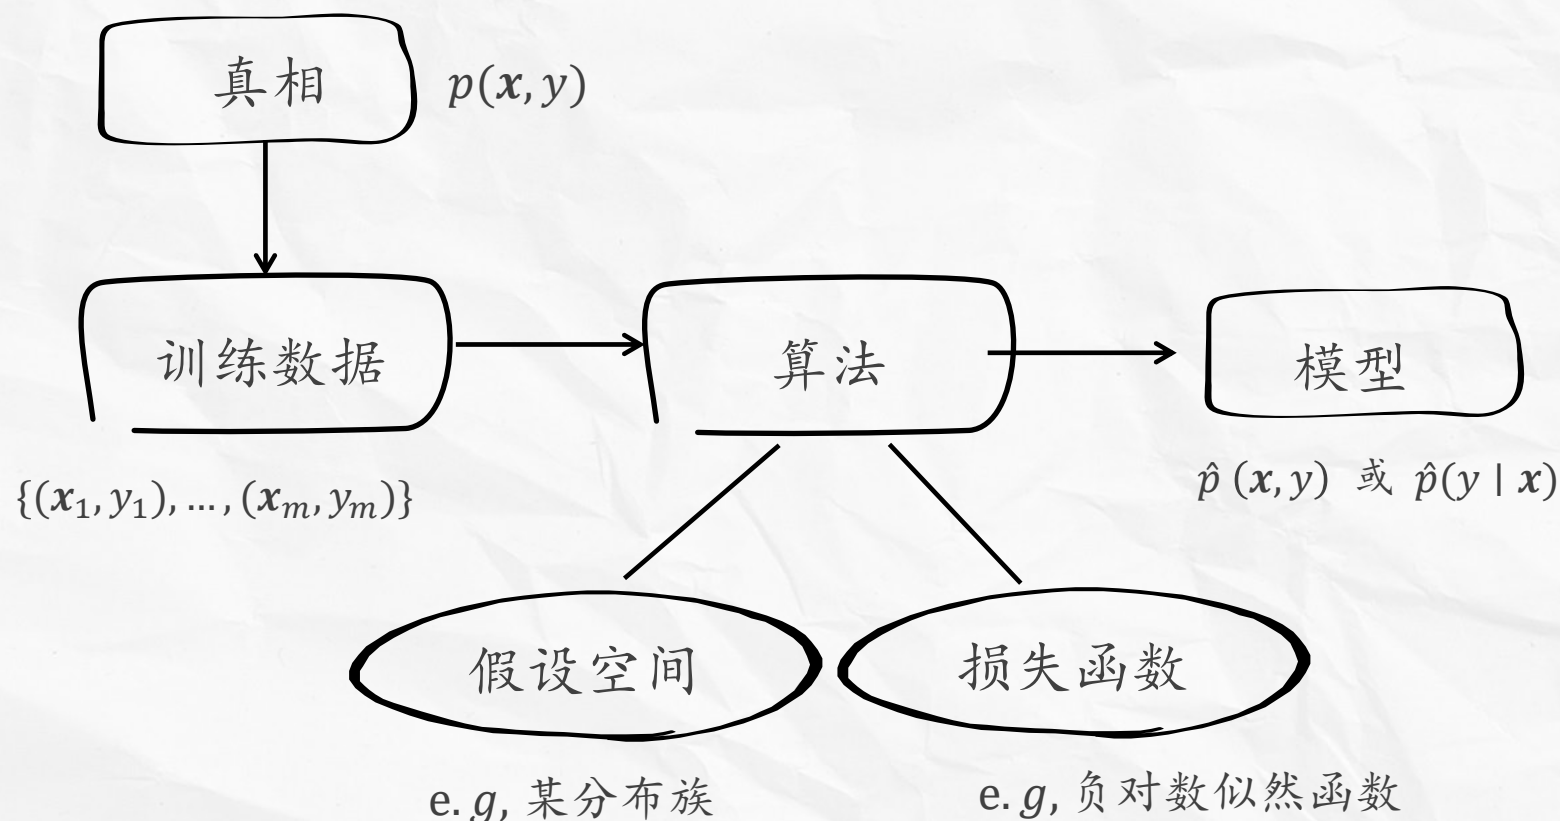
扩展：利用线性回归实现多项式回归

- PolynomialFeatures in Sklearn

<https://scikit-learn.org/stable/modules/generated/sklearn.preprocessing.PolynomialFeatures.html>

扩展：概率论角度下的线性回归

机器学习框架 (概率论角度)



扩展：概率论角度下的线性回归

◦ 概率论角度的最小二乘法

- 假设 $p(y | \mathbf{x})$ 服从高斯分布，高斯分布的均值参数由线性函数 $f(\mathbf{x}, \mathbf{w})$ 给出，其中 \mathbf{w} 为模型参数，方差记为 β^{-1}

$$p(y | \mathbf{x}, \mathbf{w}, \beta) = \mathcal{N}(y | f(\mathbf{x}, \mathbf{w}), \beta^{-1}), \quad y = f(\mathbf{x}, \mathbf{w}) + \epsilon, \quad \epsilon \sim \mathcal{N}(0, \beta^{-1})$$

扩展：概率论角度下的线性回归

◦ 概率论角度的最小二乘法

- 给定训练样本集： $\mathbf{X} = \{\mathbf{x}_1, \dots, \mathbf{x}_m\}$, $\mathbf{y} = \{y_1, \dots, y_N\}$
- \mathbf{w} 的(条件)似然函数： $p(\mathbf{y} | \mathbf{X}, \mathbf{w}, \beta) = \prod_{i=1}^m \mathcal{N}(y_i | f(\mathbf{x}_i, \mathbf{w}), \beta^{-1})$
- 对数似然函数： $\ln p(\mathbf{y} | \mathbf{X}, \mathbf{w}, \beta) = \sum_{i=1}^m \ln \mathcal{N}(y_i | f(\mathbf{x}_i, \mathbf{w}), \beta^{-1})$
- 改写对数似然函数：

$$\frac{m}{2} \ln \beta - \frac{m}{2} \ln(2\pi) - \beta E_D(\mathbf{w}), \quad E_D(\mathbf{w}) = \frac{1}{2} \sum_{i=1}^m \{y_i - f(\mathbf{x}_i, \mathbf{w})\}^2$$

- \mathbf{w} 的最大似然估计(MLE):

$$\mathbf{w}_{MLE}^* = \arg \max_{\mathbf{w}} \ln p(\mathbf{y} | \mathbf{X}, \mathbf{w}, \beta)$$

- 有结论：

$$\mathbf{w}_{MLE}^* = \mathbf{w}_{LS}^*$$

扩展：概率论角度下的线性回归

◦ 最大似然估计与最大后验估计

> 最大似然估计

假设 $p(\mathbf{z} | \boldsymbol{\theta})$ 的概率密度函数形式（ $\boldsymbol{\theta}$ 的似然分布）： $q(\mathbf{z}; \boldsymbol{\theta})$

$$\mathcal{D} = \{\mathbf{z}\}_{i=1}^n$$

Likelihood $p(\mathcal{D} | \boldsymbol{\theta})$

$$\hat{\boldsymbol{\theta}}_{\text{MLE}} = \arg \max_{\boldsymbol{\theta}} p(\mathcal{D} | \boldsymbol{\theta}) = \arg \max_{\boldsymbol{\theta}} \prod_{i=1}^m q(\mathbf{z}_i; \boldsymbol{\theta})$$

$$\hat{\boldsymbol{\theta}}_{\text{MLE}} = \arg \max_{\boldsymbol{\theta} \in \Theta} \log L(\boldsymbol{\theta}) = \arg \max_{\boldsymbol{\theta} \in \Theta} \left[\sum_{i=1}^m \log q(\mathbf{z}_i; \boldsymbol{\theta}) \right]$$

$$p(\mathbf{z}) = q(\mathbf{z}; \hat{\boldsymbol{\theta}}_{\text{MLE}})$$

扩展：概率论角度下的线性回归

◦ 最大似然估计与最大后验估计

> 最大后验估计

假设 $p(\mathbf{z} | \boldsymbol{\theta})$ 的概率密度函数形式（ $\boldsymbol{\theta}$ 的似然分布）： $q(\mathbf{z}; \boldsymbol{\theta})$

假设 $\boldsymbol{\theta}$ 的先验概率分布： $p(\boldsymbol{\theta})$

得到 $\boldsymbol{\theta}$ 的先验概率分布： $p(\boldsymbol{\theta} | \mathcal{D})$

$$\mathcal{D} = \{\mathbf{z}\}_{i=1}^n$$

Posterior $p(\boldsymbol{\theta} | \mathcal{D})$

$$\hat{\boldsymbol{\theta}}_{\text{MLE}} = \arg \max_{\boldsymbol{\theta}} p(\boldsymbol{\theta} | \mathcal{D})$$

$$\boldsymbol{\theta}_{\text{MAP}} = \arg \max_{\boldsymbol{\theta}} \left(\sum_{i=1}^m \log q(\mathbf{z}_i | \boldsymbol{\theta}) + \log p(\boldsymbol{\theta}) \right)$$

$$p(\mathbf{z}) = q(\mathbf{z}; \hat{\boldsymbol{\theta}}_{\text{MAP}})$$

扩展：概率论角度下的线性回归

◦ 概率论角度的岭回归

- 给定训练样本集： $\mathbf{X} = \{\mathbf{x}_1, \dots, \mathbf{x}_m\}$, $\mathbf{y} = \{y_1, \dots, y_N\}$
- \mathbf{w} 的(条件)似然函数： $p(\mathbf{y} | \mathbf{X}, \mathbf{w}, \beta) = \prod_{i=1}^m \mathcal{N}(y_i | f(\mathbf{x}_i, \mathbf{w}), \beta^{-1})$
- \mathbf{w} 的先验分布： $p(\mathbf{w} | \alpha) = \mathcal{N}(\mathbf{w} | \mathbf{0}, \alpha^{-1} \mathbf{I})$
- 推出 \mathbf{w} 的后验分布：

$$p(\mathbf{w} | \mathbf{y}) \propto \prod_{i=1}^m \mathcal{N}(y_i | f(\mathbf{x}_i, \mathbf{w}), \beta^{-1}) \mathcal{N}(\mathbf{w} | \mathbf{0}, \alpha^{-1} \mathbf{I})$$

- \mathbf{w} 的后验似然估计(MAP):

$$\begin{aligned} \mathbf{w}_{MAP}^* &= \arg \max_{\mathbf{w}} \ln p(\mathbf{w} | \mathbf{y}) \\ &= \arg \max_{\mathbf{w}} \left(-\frac{\beta}{2} \sum_{i=1}^m \{y_i - f(\mathbf{x}_i, \mathbf{w})\}^2 - \frac{\alpha}{2} \mathbf{w}^T \mathbf{w} + \text{const} \right) \end{aligned}$$

- 有结论：

$$\mathbf{w}_{MAP}^* = \mathbf{w}_{RR}^*$$