

MACHINE LEARNING

# 机器学习

Bayesian Classification


## 贝叶斯分类



Machine Learning Course  
Copyright belongs to Wenting Tu.

# 概率论与机器学习

- 分类任务的概率体系框架



# 分类任务的决策论

- 关于分类任务的决策理论
  - 如何做出最优的分类决策（二分类  $\{\mathcal{C}_k\} = \{-1, +1\}$  情况）


$$\begin{aligned} p(\text{mistake}) &= p(\mathbf{x} \in \mathcal{R}_1, \mathcal{C}_2) + p(\mathbf{x} \in \mathcal{R}_2, \mathcal{C}_1) \\ &= \int_{\mathcal{R}_1} p(\mathbf{x}, \mathcal{C}_2) d\mathbf{x} + \int_{\mathcal{R}_2} p(\mathbf{x}, \mathcal{C}_1) d\mathbf{x} \end{aligned}$$

$$\mathcal{R}_1 = \{\mathbf{x} \mid p(\mathbf{x}, \mathcal{C}_1) > p(\mathbf{x}, \mathcal{C}_2)\}$$

$$\mathcal{R}_2 = \{\mathbf{x} \mid p(\mathbf{x}, \mathcal{C}_1) \leq p(\mathbf{x}, \mathcal{C}_2)\}$$

$$p(\mathbf{x}, \mathcal{C}_k) = p(\mathcal{C}_k \mid \mathbf{x})p(\mathbf{x})$$

$$\mathcal{R}_k = \{\mathbf{x} \mid p(\mathcal{C}_k \mid \mathbf{x}) \text{ 是最大的} \}$$




# 分类任务的决策论

- 关于分类任务的决策理论
  - 如何做出最优的分类决策（多分类 $\{C_k\} = \{1, \dots, K\}$ 情况）

$$p(\text{mistake}) = \sum_{k=1}^K \sum_{j \neq k} p(\mathbf{x} \in \mathcal{R}_j, C_k) = \sum_{k=1}^K \sum_{j \neq k} \int_{\mathcal{R}_j} p(\mathbf{x}, C_k) d\mathbf{x}$$

$$p(\text{correct}) = \sum_{k=1}^K p(\mathbf{x} \in \mathcal{R}_k, C_k) = \sum_{k=1}^K \int_{\mathcal{R}_k} p(\mathbf{x}, C_k) d\mathbf{x}$$

$$\mathcal{R}_k = \{\mathbf{x} | p(C_k | \mathbf{x}) \text{ 是最大的} \}$$




# 分类任务的决策论

- 关于分类任务的决策理论
  - 如何做出最优的分类决策（带损失 $L_{kj}$ 情况下）


$\mathbf{x}$ 分类为 $k$ 类的损失为 $\sum_{j=1}^C L_{kj} p(\mathcal{C}_j | \mathbf{x})$

$\mathcal{R}_k = \{\mathbf{x} | \sum_{j=1}^C L_{kj} p(\mathcal{C}_j | \mathbf{x}) \text{ 是最小的} \}$





# 概率论与机器学习

- 生成式算法与判别式算法



# 分类任务的决策论

- 生成式算法与判别式算法



# 朴素贝叶斯

- 动机

估计后验概率 $P(c | \mathbf{x})$ 的主要困难在于: 类条件概率 $P(\mathbf{x} | c)$ 是所有属性上的联合概率, 难以从有限的训练样本直接估计而得.

- 想法

假设所有属性在给定类别的条件下相互独立 — 属性条件独立性假设 ”  
*attribute conditional independence assumption*

$$\hat{p}(c | \mathbf{x}) = \frac{\hat{p}(c)\hat{p}(\mathbf{x} | c)}{\hat{p}(\mathbf{x})} = \frac{\hat{p}(c)}{\hat{p}(\mathbf{x})} \prod_{i=1}^d \hat{p}(x_i | c)$$

$$h_{nb}(\mathbf{x}) = \arg \max_{c \in \mathcal{Y}} \hat{p}(c) \prod_{i=1}^d \hat{p}(x_i | c)$$

$$\hat{p}(c) = \frac{|D_c|}{|D|}$$



# 朴素贝叶斯

- 单变量类条件概率 $p(x_i | c)$ 的估计
- 离散变量情况

$$\hat{p}(x_i | c) = \frac{|D_{c,x_i}|}{|D_c|} \xrightarrow[\text{Laplacian correction}]{\text{smoothing}} \hat{p}(x_i | c) = \frac{|D_{c,x_i}| + 1}{|D_c| + N_i}$$

$$\left( \hat{p}(c) = \frac{|D_c|}{|D|} \xrightarrow[\text{Laplacian correction}]{\text{smoothing}} \hat{p}(c) = \frac{|D_c| + 1}{|D| + N} \right)$$

- 连续变量情况

$$\hat{p}(x_i | c) \sim \mathcal{N}(\mu_{c,i}, \sigma_{c,i}^2)$$

# 生成式算法与判别式算法

- 朴素贝叶斯 vs 逻辑回归

不同于逻辑回归，朴素贝叶斯等方法是通过刻画先验与似然来实现贝叶斯分类的。这引出了贝叶斯算法的两种类型：

一种是直接对后验概率 $p(\mathcal{C}_k | \mathbf{x})$ 建模

一种是对联合概率 $p(\mathbf{x}, \mathcal{C}_k)$ 或 $p(\mathbf{x} | \mathcal{C}_k) \& p(\mathcal{C}_k)$ 建模。

前者我们称为是判别式算法，后者我们称为是生成式算法